

データサイエンスキャップストーン 最終レポート

SpaceX Falcon 9 第1段階着陸成功予測

本レポートは、SpaceX API・Webスクレイピング・SQL・EDA・Folium・Plotly Dash・機械学習を統合したキャップストーン成果物の提出用サマリーです。提出前確認として、使用データ、分析手順、結果、限界、今後の改善を明記し、再現可能なNotebookとPythonコードをGitHubリポジトリに収録しています。

1. 背景と目的

Falcon 9は第1段を再利用できるため、着陸成功の予測は打上げコストや運用判断に関係します。本研究では、過去の打上げ記録から、ロケット仕様、ペイロード、軌道、発射場、再利用情報などを整理し、第1段が着陸に成功するかを二値分類します。

2. 分析ワークフロー

段階	実施内容	成果物
収集	SpaceX APIから打上げJSONを取得し、IDを補完	hands-on_API.ipynb
補完	Wikipedia表をBeautifulSoupで取得	webscraping.ipynb
整形	欠損値処理、Falcon 9抽出、Class作成	データラングリングNotebook
分析	発射場、軌道、成功率、時系列、SQL集計	EDA / SQL Notebook
可視化	散布図、地図、インタラクティブ表示	Folium / Plotly Dash
予測	Logistic Regression、SVM、Decision Tree、KNN	機械学習予測Notebook

3. 課題指定項目の明記

提出PDF内で確認すべき要素を、以下の5項目として明示します。

項目	記載内容
使用データ	SpaceX APIで取得した打上げ・ ロケット・ ペイロード・ 発射台・ 第1段コア情報、WikipediaからスクレイピングしたFalcon打上げ履歴、各Notebookで整形した分析用データを使用しました。主な変数は発射場、軌道、payload mass、booster version、再利用数、grid fins / legs、landing outcome、Classです。
分析手順	API収集、Webスクレイピング、Falcon 9への絞り込み、欠損値補完、Class作成、SQL集計、EDA可視化、Folium地図、Plotly Dashダッシュボード、標準化と学習データ分割、4種類の分類モデル比較の順に実施しました。
結果	発射場別・ 軌道別・ payload別に着陸成功率の違いを確認しました。SQLではNASA (CRS) payload合計45,596 kg、F9 v1.1 payload平均2,534.67 kg、2015年のdrone ship failure 2件などを確認しました。機械学習ではLogistic Regression、SVM、KNNがTest accuracy 0.833で同率となり、解釈性も考慮してLogistic Regressionを第一候補としました。
限界	公開データ中心のためサンプル数が限られ、天候、詳細な機体状態、運用判断、打上げ時点の外部条件などは十分に反映できていません。欠損値補完や訓練・ テスト分割の影響も残るため、結果は因果推論ではなく予測モデルの比較として解釈する必要があります。
今後の改善	最新打上げデータの継続追加、気象・ ミッション難易度・ booster整備履歴などの特徴量追加、交差検証の強化、確率校正、SHAPなどによる説明可能性の追加、Dashアプリの入力UI改善を行うことで、予測精度と実務での説明力を高められます。

以上により、PDF単体でもデータ、方法、発見、制約、次の改善方針が確認できる構成にしています。

4. 主要な分析結果

指標	結果
発射場	CCAFS LC-40 / CCAFS SLC-40 / KSC LC-39A / VAFB SLC-4E
NASA (CRS) payload合計	45,596 kg
F9 v1.1 payload平均	2,534.67 kg
地上パッド初回成功	2015-12-22
最大payloadを搭載したboosters	F9 B5系を中心に複数
2015年 drone ship failure	2件 (1月・ 4月)
SQLのlanding outcome集計	No attempt 10、Success drone ship 5、Failure drone ship 5、Success ground pad 3 など

5. 機械学習モデル比較

モデル	CV accuracy	Test accuracy
Logistic Regression	0.846	0.833
Support Vector Machine	0.848	0.833
Decision Tree	0.888	0.667
K Nearest Neighbors	0.848	0.833

テストデータではLogistic Regression、SVM、KNNが同率の0.833で、Decision Treeは0.667でした。CVとテストの両方を考慮すると、解釈しやすく安定したLogistic Regressionを実務上の第一候補とします。

6. 評価項目への対応

評価	対応状況
1.1 GitHub URL	完了：本リポジトリに記載
1.3～1.9 収集・整形・EDA・SQL	完了：各Notebookを登録
1.10～1.14 可視化	完了：Folium、Plotly Dash、画像を登録
1.15 モデル比較	完了：4モデルのCV / Test結果を記載
最終PDF	本PDFで対応
プレゼンテーションPDF	別PDFで対応
Markへの提出	ユーザーによる最終アップロードが必要

7. 全タスク確認表

PDF提出前に、評価基準に記載された15項目を個別に確認しました。各項目はGitHub上のNotebook、Pythonファイル、画像、または本レポートに対応しています。

項目	要求	状態	確認資料
1.1	プロジェクトのGitHub URLを提出	完了	本レポートとREADMEにURLを記載
1.2	完成した最終レポートをPDF形式で提出	完了	本PDFを作成しGitHubへ登録
1.3	サマリー、方法、主要結果を明記	完了	本レポートの概要・ワークフロー・結果
1.4	導入で背景と問題を説明	完了	hands-on_API.ipynb と本レポート1章
1.5	SpaceX APIを使用したデータ収集	完了	hands-on_API.ipynb
1.6	Webスクレイピングによるデータ収集	完了	webscraping.ipynb
1.7	データ整形・欠損値処理・前処理	完了	ハンズオンラボデータラングリング.ipynb
1.8	EDAとデータクリーニングの説明	完了	可視化EDAラボ.ipynb
1.9	SQLクエリによるEDA結果の要約	完了	ピアグレーデッドアサインメント.ipynb
1.10	FoliumマップとPlotly Dashを作成	完了	ハンズオンラボFoliumラボ.ipynb / Plotly Dash.py
1.11	散布図・棒グラフ・年次トレンド等のEDA可視化	完了	可視化EDAラボ.ipynb と画像2点
1.12	発射サイト、payload、成功率、ランキング、時間分析	完了	EDA / SQL Notebookの出力
1.13	発射サイトマーカー、発射記録、近接分析の地図	完了	ハンズオンラボFoliumラボ.ipynb
1.14	成功率とpayload・発射サイトの散布図	完了	可視化EDAラボ.ipynb / Plotly Dash.py
1.15	複数モデルを比較し最良モデルを説明	完了	機械学習予測ラボ.ipynb、本レポート4章

GitHub: <https://github.com/madao009papa/github-getting-started-lab-20260811>

出典: 保存済みNotebookの実行結果、SpaceX API / Skills Network提供データ、Wikipediaスクレイピング結果。